

新媒体与社会
New Media and Society
ISSN ,CN

《新媒体与社会》网络首发论文

题目：形式信任与递进归谬：人工智能生成内容可信度评估研究
作者：杨艳妮，武雷龙，向安玲，张家铖
网络首发日期：2025-09-11
引用格式：杨艳妮，武雷龙，向安玲，张家铖. 形式信任与递进归谬：人工智能生成内容可信度评估研究[J/OL]. 新媒体与社会.
<https://link.cnki.net/urlid/CN.20250910.1710.008>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

形式信任与递进归谬：人工智能生成内容可信度评估研究*

杨艳妮 武雷龙 向安玲 张家铖**

摘要 构建科学有效的 AIGC 可信度测评体系是当前人机信任研究的重要议题。本研究融合智能传播视角下对 AIGC 媒介属性的考察，从底层技术构架、中间层媒介渠道到面向用户交互的信息内容，自底向上搭建综合、系统的 AIGC 可信度评估体系。基于层析分析法，在专家充分论证的基础上，明晰 AIGC 可信度的主要影响要素。研究表明，内容可信是影响用户感知 AIGC 可信的第一要素，输出结果和训练数据对系统可信、立场中立性和社会影响力对媒介可信、实质可信和形式可信对内容可信等会产生显著影响。并提出从系统技术、媒介平台、内容线索以及用户反向验证等方面增强 AIGC 可信的优化策略，为 AIGC 产品优化设计、用户信任构建、信息生态治理提供借鉴。

关键词 人工智能生成内容 可信度 评估框架 形式信任 递进归谬

Formal Trust and Hierarchical Fallacy: Research on the Assessment of Credibility of Artificial Intelligence Generated Content

Yanni Yang, Leilong Wu, Anling Xiang, Jiacheng Zhang

Abstract Establishing a scientific and effective credibility evaluation system for AIGC has become a crucial topic in human-machine trust research. This study integrates the AIGC's media

* 基金项目：国家自然科学基金青年项目“面向人工智能生成内容的风险识别与治理策略研究”（项目编号：72304290）。

** 杨艳妮，三峡大学文学与传媒学院副教授；武雷龙，三峡大学文学与传媒学院硕士生；向安玲，中央民族大学新闻与传播学院讲师；张家铖，清华大学新闻与传播学院博士后。

attributes from the perspective of intelligent communication and constructs a comprehensive and systematic AIGC credibility evaluation framework from the bottom up—spanning the underlying technical architecture, intermediary media channels, to user-interactive information content. Utilizing hierarchical analysis and based on extensive expert discussion and argumentation, the study identifies the primary factors influencing AIGC credibility. Research findings indicate that content credibility is the foremost factor affecting users' perception of AIGC trustworthiness. Output results and training data significantly impact system credibility, while neutrality and social influence affect media credibility, and substantive and formal credibility influence content credibility. The study proposes optimization strategies to enhance AIGC credibility, focusing on system technology, media platforms, content cues, and user reverse verification, offering insights for AIGC product design optimization, user trust building, and information ecosystem governance.

Keywords AIGC; Credibility; Evaluation Framework; Formal Trust; Hierarchical Fallacy

一 研究缘起：AIGC 背景下可信传播之痛

当下全球信息内容生产正在历经一次全新的代际革命。在大语言模型等技术的加持下，人工智能生成内容（Artificial Intelligence Generated Content, AIGC）在生产规模和产出效率上都超越了传统的 PGC（Professional Generated Content, 专业生产内容）和 UGC（User Generated Content, 用户生成内容），逐步成为 Web3.0 时代媒介内容生产的新引擎。在 AIGC 加速渗透到行业应用与大众传播的过程中，以人为中心的内容生产与传播范式也开始转向人机协同共生的生态格局，AI 在议程建构、内容把关、信息分发等环节中的拟主体性地位凸显，信息生产模式和信息权力也面临着失衡与重构，由此所衍生的人机信任问题成为 AIGC 发展之掣肘。

尤其是在可信内容供给上，当下 AIGC 产品饱受诟病。一方面，受限于大语言模型的训练语料数据的开放性，及其基于概率统计的内容生成逻辑，概念混淆、事实拼接、时空错位、强加因果等错误在部分 AIGC 产品的内容生成中频现，事实核查成为多数 AIGC 产品之“硬伤”。另一方面，尽管 AIGC 相关算法本身没有善恶属性，但这项技术已被广泛用于政治操纵和不正当商业竞争等负面目的^[1]，如 AI 生成的虚假新闻、批量生成的虚假信息等^[2]。此

外，包括图片、视频、音频等在内的多模态 AIGC 在视觉层面具备较强混淆性，进一步加剧了虚假信息和误导信息的传播，对国际政治、社会和人权发展都带来了新的挑战^[3]。

面对 AIGC 衍生的内容失实与人机信任等问题，多个国家地区从顶层设计层面加强制度约束和法律保障，我国也先后推出《新一代人工智能伦理规范》《互联网信息服务深度合成管理规定》《生成式人工智能服务管理办法（征求意见稿）》等政策文件，明确指出“利用生成式人工智能生成的内容应当真实准确”。国内外 AIGC 平台方也通过算法迭代、模型修正与人工审查等多重约束提升内容质量，但更多局限于政治信息与敏感内容，通用领域的可信传播仍是行业发展痛点。从用户端来看，相比于欧美国家用户对 AIGC 的批判性态度，中国用户对 AIGC 的应用表现出更明显的积极态度^[4]，用户对署名为算法新闻的感知可信度甚至高于对人类记者的信任度^[5]。这种对 AIGC 的高感知信任度与乐观取向若缺乏理性引导，可能助长不实信息的传播，给舆论环境和信息安全带来新的风险。

在 AIGC 产品加速渗透到大众级应用市场的当下，用户对其感知信任度如何？受到哪些因素影响？如何对 AIGC 可信度进行有效测评？一系列问题都还有待进一步探讨。在此背景下，以当下国内外典型文本类人工智能生成内容为研究对象，基于可信 AI 框架、媒介信任、双重加工理论等从系统可信、媒介可信、内容可信三个维度构建 AIGC 可信度评估体系，以挖掘影响可信度的主观感知因素和客观技术因素，以期智能传播与信息生态治理提供理论参考和实践指导。

二 文献回顾：可信系统、可信媒介与可信内容

可信度这一研究主题具有显著的跨学科特征，如传播学、管理学、计算机科学、心理学等多个学科对其均开展了相关探索，各研究学者对可信度的解析也各有差异。整体来看，对 AIGC 可信度的分析主要从以下几个角度展开：一是，将可信度看作是多个侧面或维度共同组成的整体。吴丹等人从内容整合性、问答交互性、工具拟人性三个维度分析它们对生成式智能搜索可信度的影响^[6]。蒋忠波等人设置准确性、可信、偏见、真实、权威性五个题项对可信度进行测量。二是，通过可信度的来源对可信度进行解释^[5]。Fogg 等人提出从信源角度诠释可信度，如由刻板印象等推定而来的推定可信度、由第三方背书认证产生的信誉可信度、由外部特征得到的表面可信度、从经验判断的经验可信度等^[7]。三是，将可信度的主体归纳为若干类别进行分析。宋士杰等人提出未来从信息源、交互方式、社会活动者、算法隐

喻的四种视角建构 AIGC 可信度研究框架^[8]。刘海明和李佳悱认为人机交互情景下，信任一方面来源于算法系统的可靠性、可信度与负责任的内容生成，另一方面体现在聊天机器人的拟人化特征为用户互动过程带来积极的反应^[9]。此外，亦有学者以研究中涉及的研究对象命名可信度，如评论可信度、广告可信度等。

在多传统学科的可信度研究基础上，关于 AIGC 的可信度已然是一个新兴的研究话题。随着人工智能技术的广泛应用，除了将人工智能看作软件系统从系统技术层面衡量其可信度以及传统研究中从信息内容层面对内容可信的分析，研究学者们认识到 AI 作为媒介的价值和重要性，因此在关于 AIGC 可信度的阐释当中，也需要从媒介维度考察其可信度。从系统可信、媒介可信、内容可信三个维度综合梳理国内外典型的相关研究成果，如表 1 所示，囿于篇幅仅做少量列举。

表 1 国内外可信度评估相关研究成果

评估视角	评估维度	研究者	评价思路
来源	系统可信	欧盟 ^[10]	可追责性、普惠性、自主性、公平性、隐私性、鲁棒性、安全性、透明性
		OECD ^[11]	可持续发展、价值观、公平性、透明性、可解释性、鲁棒性、安全性、防危性
		Singh ^[12]	公平性、可解释性、鲁棒性、隐私性、安全性、得体性
		Fujii ^[13]	完整性、鲁棒性、系统质量、敏捷性
		何积丰 ^[14]	鲁棒性、自我反省性、自适应性和公平性
渠道	媒介可信	Schweiger ^[15]	媒介类型、媒介子类别、媒介产品、编辑单位、信息创造者、信息呈现者
		Metzger ^[16]	信源、信息和传输信息的渠道
		李晓静 ^[17]	媒介机构/新闻从业者（信源）可信度、新闻报道（信息）可信度等
		张洪忠和任昊炯 ^[18]	大众媒体公信力、社交媒体信任、基于机器身份的人机信任、基于语言对话的人机信任
内容	内容可信	Sundar ^[19]	MAIN 模型（从技术可供到可信度判断）
		Flanagin 和 Metzger ^[20]	双处理模型（启发式、系统式）

		Hilligoss 和 Rieh ^[21]	可信度评估整合框架（建构层、探索层、交互层）
--	--	----------------------------------	------------------------

系统可信维度来看，可信评估是确保系统可信必不可少的部分，人工智能系统可信度评估目前涌现较多相关成果，被应用于各类人工智能系统的可信度评估。欧盟委员会在 2019 年提出的可信人工智能伦理指南草案^[10]，对可信 AI 提出 10 项基本要求。国际经济与合作组织（OECD）在此基础上又增加了包容性增长、可持续发展和福祉等长期性指标^[11]。中国信通院逐步构建和完善“可信 AI”评测体系，重点对 AI 产品服务能力、应用和管理成熟度和可信风险进行评测^[22]。Singh 等人对人工智能提出了公平性、可解释性、鲁棒性、隐私性、安全性、得体性 6 个可信属性^[12]。Fujii 等人则更强调完整性、鲁棒性、系统质量以及敏捷性^[13]。何积丰也提出人工智能应具有鲁棒性、自我反省性、自适应性和公平性^[14]。

媒介可信维度来看，随着新媒介技术的大量涌现，受众接触的媒介种类、媒介使用习惯、媒介认知判断等发生巨大转变。Schweiger 归纳西方学者对媒介可信度评估的六个维度，分别是媒介类型、媒介子类别、媒介产品、编辑单位、信息创造者、信息呈现者等^[15]。Metzger 等人建议对信源、信息和传输信息的渠道分开测量^[16]。李晓静依照中国的实际媒介环境和受众特质，侧重从媒介机构/新闻从业者（信源）可信度、新闻报道（信息）可信度等角度展开研究^[17]。张洪忠等人将媒介信任分为基于内容与载体的大众媒体公信力、基于价值观认同的社交媒体信任、基于机器身份的人机信任、基于语言对话的人机信任^[18]。

内容可信维度来看，当下人类和机器生产的信息内容生产达到前所未有的规模，对信息内容可信度评估成为当下重要议题。关于内容可信度的评估，涉及领域宽泛，从传统内容资源到 UGC、PGC、AIGC 等。众多学者开展相关研究，Sundar 提出 MAIN 模型用于评估新媒体环境下的信息可信度^[19]。Flanagin 和 Metzger 提出双处理模型，认为用户评估信息可信度的路径有两种，一种是启发式处理，另一种是系统式处理^[20]。Hilligoss 和 Rieh 提出的可信度评估整合框架认为评估过程涉及建构层、探索层、交互层三个层次，分别对应用户对可信度的定义、启发式的思考、基于信息线索的判断^[21]。

综合而言，由于人机对话的 AIGC 系统本身特有性质，对于 AIGC 可信度的评估需要从系统可信、媒介可信、内容可信三个维度展开，一方面是借鉴以往研究成果，另一方面是针对 AIGC 系统本身的可信性研究其可信度量的方法，不仅仅需要拓展研究视角，且需要面向 AIGC 发展特征，从底层技术构架、中间层媒介渠道到面向用户交互的信息内容，自底向上搭建综合、系统的可信度评估体系。

三 评估框架：AIGC 可信度评估体系构建与评估方法

为了进一步探讨 AIGC 可信线索及不同产品的可信度差异，本研究通过前期文献调研构建 AIGC 可信度评估体系，并结合专家调研评分对指标进行分析，以构建 AIGC 可信度评估框架，在此基础上，通过层次分析法确定各项指标权重，以明确各相关因素的重要程度。

（一）AIGC 可信度评估体系构建

依据国内外相关研究采纳较为广泛的评估思路，即来源（信源可信）、渠道（媒介可信）和内容（内容可信）三个大的理论研究方向^[17]，依照本研究的具体情景，从系统可信度、媒介可信度和内容可信度三个层面对 AIGC 进行评估，如图 1 所示。基于前期文献调研，结合 AIGC 相关技术和产品应用特色，汇总现有系统、媒介、内容可信度指标。由此初步拟定 AIGC 可信度评估指标，从而确定评估指标框架。其中对系统可信的分析是与 AIGC 技术架构直接相关的核心维度，内容可信的考察是传统可信度研究的延续和继承，对媒介可信的关注则是智能传播视角在可信度研究主题领域中的拓展。




图 1 AIGC 可信度评估体系

1. 系统可信度

从系统技术层面来看，“可信性”是在系统“可靠”“安全”等概念的基础上发展而来的一项系统指标，是人类对系统研发与应用过程中各种可信属性的一种整体评价^[23]。既反映了系统本身的客观性能，也体现了用户对系统的主观感知。相比于早期可信系统对硬件设备的关注，可信人工智能（trustworthy AI）更多关注软件层面的可信属性，是指 AI 系统在设计、开发、部署和使用过程中，基于其产品性能和风险保障等属性，以获取用户和社会的信任 and 接受^[24]。

人工智能系统的可信性依赖于大量高质量、可靠的数据支撑，恰当的算法模型应用和符合

预期的输出结果。综合 AIGC 技术特性和既有相关研究,对于 AIGC 产品,系统可信度测评需从底层训练数据、算法模型和输出结果三方面综合考量。其中底层数据潜藏的噪音、偏见和隐私侵犯风险在很大程度上影响了生成内容的可信度。在算法模型层面,生成式人工智能通过基于人类反馈的强化学习,在某种程度上让其可与人类的常识、认知、需求甚至价值观保持一致。同时引入了过滤机制来屏蔽敏感问题(如暴力、犯罪、歧视等),通过拒绝回答或反馈相对中庸、稳妥的回复来降低传播风险。这种算法层面的伦理制约和优化机制在一定程度上保障了内容安全性,但算法的“可塑”特性也增加了 AI 本身的“规训”风险,恶意训练带来的内容失信风险也不容忽视。此外,受限于统计语言模型的底层计算逻辑及交互指令(prompt)有效性,AI 输出结果也存在不稳定性。

基于相关研究,本研究对训练数据层着重从数据集透明性、信源可靠性、数据稳健性、数据覆盖度、数据可扩展性、噪音剔除和信源安全性等角度进行分析。算法模型层侧重从模型可解释性、鲁棒性、稳定性、自适应性、隐私保护和可塑性进行评估。输出结果方面,则需对生成内容的精度、错误率、查准率、查全率、召回率等指标进行分析。

2. 媒介可信度

AIGC 背景下媒介组织、算法平台和内容生产者之间的边界趋于模糊,AI 算法作为一种技术手段,其内嵌了内容生产、分发与议程设置能力,逐步呈现出深度媒介化趋势。AIGC 作为一种新兴媒介形态,如果说技术可信度是从底层运作逻辑层面对 AIGC 的考量,那么媒介可信度更多是将 AIGC 作为一种媒介载体和传播主体对其公信力进行评估。

媒介可信度是指技术渠道和特定信息传播组织是否值得信赖^[25]。在早期关于媒介可信度(media credibility)的研究中,传播者的能力(competency)即专业化程度是影响可信度的核心因素^[26]。能力不仅包括媒介在专业领域的深耕程度和权威性,同时也包括其在信息把关、包装和分发等传播环节上的专业化程度。它直接决定了媒介是否能输出正确可信的信息,同时也关系到媒介本身的品牌背书,即能否对信息内容的真实性负责。后续相关研究在媒介能力的基础上,又增加了无私(unselfishness)、一致性(consistency)等因素^[27, 28]。“无私”关系到媒介的传播动机是否正当与纯粹,也即媒介本身与其所报道主体、所涉及议题是否存在利益关联。对于内容输出平台而言,一致性更多体现在其是否存在价值偏见和前后冲突。除了在内容输出层面保障专业度、无私性、一致性,通过与受众进行有效互动、提供反馈闭环、建立透明度和道德标准、第三方独立组织机构认证等外部手段也可以帮助媒介提升可信度^{[29][30]}。

基于相关文献调研,结合 AIGC 的技术特性,本研究从专业服务能力、社会影响力、立

场中立性、保障机制构建四个层面对其媒介可信度进行评估。其中专业服务能力主要针对 AIGC 平台在专业领域的内容沉淀、专业媒体合作、规范化流程机制等；社会影响力包括平台的社会知名度、社会评价、第三方认证和背书等；立场中立性包括平台的无私性、一致性、独立性、盈利性等；而保障机制构建则涉及平台的用户反馈机制、追责机制、隐私机制/数据安全机制等方面，关系到平台是否能保障信息质量和安全性。

3. 内容可信度

依照双重加工理论，人类在处理和推理信息时往往会激活双重认知系统，一种是快速的、直觉性的、感性处理方式，另一种是慢速的、有所控制的、理性的思维方式^[31]。前者可以在短时间内处理大量信息，并快速作出判断、生成答案，而后者则需要通过逻辑推理和抽象思维来形成判断、验证答案。对应到信任机制上，直觉式信息处理往往会激发“形式信任”，而控制型信息处理则会形成“实质信任”。其中形式信任更多是基于内容的表面特征和可信线索产生的认同感，不同的可信线索通过激活用户既有认知结构和态度倾向，形成认知捷径，进一步帮助用户判断内容的可信程度。从内容属性来看，包括信息情绪化程度、内容中多媒体形态使用、是否提及其他用户、信息中包含的外链/信源声誉、特定词汇使用等^[32]。从外部线索来看，包括社会推介线索（如转赞评等数据）、时间线索（如更新频率、时效性等）、声誉线索（如历史成绩、第三方认证、诚信记录等）。形式信任往往决定了用户对内容的初始可信度，而初始可信度对于用户后续信念的变化将起到显著中介作用^[33]。

相比于形式信任，实质信任主要是对内容本质的可信度进行探讨。包括内容客观性和准确性、是否存在明显的偏见或立场倾向、是否存在明显错误或虚假信息等^[34]。内容的完整性、一致性和时效性等要素也决定了本质可信度，而用户自身的知识水平、经验和判断力直接影响了其感知差异^[35]。实质信任的形成往往需要用户对内容进行深思熟虑的分析判断和逐层递进的溯源推理，无论是在信任深度还是信任周期上都强于形式信任。面对 AIGC 产品目前普遍存在的错误混淆、事实不一致、政治偏见、信息安全、伦理风险等问题，形式层面和实质层面的可信线索分析和递进式归谬都视为必要。

基于上述讨论，本研究将 AIGC 的内容可信度划分为形式可信度和实质可信度两方面。其中形式可信度主要从 AIGC 结构特征和语言特征层面进行分析，包括引用规范性、响应一致性、表达严谨性、信源专业度、权威背书、信息噪音等；实质可信度主要针对内容本质属性进行评估，包括内容真实性、内容正确性、内容客观性、信息时效性、信息完整性、信息一致性、质量稳健性、内容安全性、内容公平性等方面。

（二）AIGC 可信度评估方法

针对目标进行决策分析，国内外学者提出多种主观或客观的评价方法。20 世纪 70 年代美国运筹学家 T.L.Saaty 教授提出的层次分析法，针对定性问题定量分析，简便灵活的多准则决策迅速受到各个领域的广泛应用。其核心思想是将复杂的决策问题分解为多个层次，并通过构建判断矩阵和一致性检验来确定各因素的权重系数。本研究首先组建专家团队，确保团队评价的一致性和有效性。其次基于层析分析法，建立层次结构模型，并由专家团队对上述构建的可信度评估框架中的指标进行评估，构造判断矩阵以及一致性检验从而对各级指标的权重进行计算和判断。

1. 专家团队组建与培训

评估专家的专业知识和经验将直接影响标注结果的准确性和可靠性。对此，本研究选取 5 位在人工智能和自然语言处理领域有丰富经验的专家，其中 2 位是算法工程师，2 位是相关学科研究学者，1 位是资深媒体从业人员，他们对 AIGC 产品具有深度使用经验，能够很好地理解各类说明文档。在进行评估标注之前由工作人员介绍本研究的背景和目的，并解释各指标的定义同时提供示例和模拟场景等，确保各位专家对评价方法有清晰的理解。为保障评估结果的稳定性和可靠性，本研究采用 Cohen's Kappa 标准测度方法对专家打分进行一致性检验。结果显示 Kappa 值为 0.647, $P<0.001$ ，表明专家们对于各个指标的理解和评价大致是一致的，可以进行后续的可信度评估。虽然打分过程涉及到主观判断，但通过严格遵守专家团队的多元性和打分方法的规范性，本研究尽可能地保证了评价结果的准确性和可靠性。

2. 指标评价与权重确定

（1）建立层次结构模型

基于前文构建的 AIGC 可信度评估框架，采用层次分析法确定一级指标和二级指标权重，首先建立递阶层次结构，分为目标层、准则层、次准则层。目标层为 AIGC 可信度评估（U），准则层包括三个一级指标，即系统可信度（U1）、媒介可信度（U2）、内容可信度（U3）。这三个主要因素又分别对应若干子因素，形成次准则层，包括训练数据可信度（U11）、算法模型可信度（U12）、输出结果可信度（U13）等 9 个子因素，其递阶层次结果如表 2 所示。

表 2 AIGC 可信度评估体系分层结构

目标层	准则层	次准则层	次准则层指标说明
AIGC	系统可信度	训练数据可信度	数据集透明性、信源可靠性、数据稳健性、数

可信度 评估 U	(U1)	(U ₁₁)	据覆盖度、数据可扩展性、噪音剔除和信源安全性
		算法模型可信度 (U ₁₂)	模型可解释性、鲁棒性、稳定性、自适应性、隐私保护和可塑性
		输出结果可信度 (U ₁₃)	生成内容的精度、错误率、查准率、查全率、召回率
	媒介可信度 (U2)	专业服务能力 (U ₂₁)	专业领域的内容沉淀、专业媒体合作、规范化流程机制
		社会影响力 (U ₂₂)	平台的社会知名度、社会评价、第三方认证和背书
		立场中立性 (U ₂₃)	平台的无私性、一致性、独立性、盈利性
		保障机制构建 (U ₂₄)	平台的用户反馈机制、追责机制、隐私机制/数据安全机制
	内容可信度 (U3)	形式可信度 (U ₃₁)	引用规范性、响应一致性、表达严谨性、信源专业度、权威背书、信息噪音
		实质可信度 (U ₃₂)	内容真实性、内容正确性、内容客观性、信息时效性、信息完整性、信息一致性、质量稳健性、内容安全性、内容公平性

(2) 构造判断矩阵

基于专家讨论综合意见，对每个层次上的指标因素进行两两比较，依据相对重要程度给予量化描述，构造比较矩阵，直到层次结构最底层。判断矩阵 M 中元素 m_{ij} 表示 i 元素对 j 元素的相对重要程度，且满足下述关系：

$$M=(m_{ij})_{n \times n}, m_{ij}>0, m_{ij}=\frac{1}{m_{ji}}, m_{ii}=1, i, j=1, 2, \cdots, n \quad (\text{式 1})$$

m_{ij} 的值越大，就说明 i 的相对重要程度越高。依据 Satty 给出的九级标度法来确定 m_{ij} 的值，如表 3 所示。

表 3 九级标度法

相对重要程度	定义	说明
1	同等重要	两个指标的重要性一样

3	略微重要	依据经验或判断，某个指标略微重要
5	颇重要	依据经验或判断，某个指标颇重要
7	极重要	实际显示，某个指标极为重要
9	绝对重要	有充分的证据表明某个指标绝对重要
2, 4, 6, 8	相邻判断的中间值	需要对指标折中判断时采用

(3) 权值计算及一致性检验

根据上述构建的判断矩阵，计算各因素相对于其上层准则层的相对重要性，即权值。本研究中采用和积法对判断矩阵进行归一化处理，求得的 W 为矩阵 M 的最大特征向量，即为各个因素的排序权重，并以此求出其特征根：

$$\lambda_{\max} = \sum_{i=1}^n \frac{(MW)_i}{nW_i} \tag{式 2}$$

尽管在前述对专家们判断的一致性进行了初步判断，但为避免专家对指标进行两两比较时出现矛盾或者不一致的结论，需要对判断矩阵进行一致性检验以保证指标权重的合理性。一般将计算的 CR 值作为判断矩阵一致性的依据，当 CR 值小于 0.1 时，即认为判断矩阵的一致性是可以接受的，否则，应对判断矩阵进行适当修正，避免计算结果的一致性偏差过大，影响评价结果的准确性。 CR 值的计算方法如下：

$$CI = \frac{\lambda_{\max} - n}{n - 1} \tag{式 3}$$

$$CR = \frac{CI}{RI} \tag{式 4}$$

上述 CI 即为一致性指标， RI 为判断矩阵的平均随机一致性指标，其取值判断矩阵的阶数，具体对应关系如表 4 所示。

表 4 平均一致性指标 RI 值

n	1	2	3	4	5	6	7	8	9
RI	0	0	0.58	0.90	1.12	1.24	1.32	1.41	1.46

具体操作而言，定义准则层指标集为 $U = \{U_1, U_2, U_3\}$ ，由层次分析得到相应的权重值集为 $A = (a_1, a_2, a_3)$ 。其中 a_i 表示 U_i 相对于目标层的比重。定义次准则层指标集为 $U_k = \{U_{k1}, U_{k2}, \dots, U_{kn}\}$ ，同理相应权重值集为 $A_k = \{a_{k1}, a_{k2}, \dots, a_{kn}\}$ ，其中 a_{kn} 表示 U_{kn} 相对于 U_k 的比重， k 表示次准则层所对应的准则层， n 表示该层指标数量。在本研究中，按照五位专家的讨论和意见，对各层指标进行判断，得到准则层判断矩阵，如表 5 所示。

表 5 $U-U_k$ 判断矩阵

$U-U_k$	U_1	U_2	U_3
U_1	1	2	1/2
U_2	1/2	1	1/5
U_3	2	5	1

通过和积法对判断矩阵进行归一化处理，解得其特征向量 W 为 $(0.277, 0.128, 0.595)^T$ ，其最大特征值为 $\lambda_{\max}=3.006$ ，对 $U-U_k$ 判断矩阵的一致性检验结果为， $CI=0.003$ ， $CR=0.005<0.1$ ，因此该判断矩阵的一致性是可以接受的， $A=(0.277, 0.128, 0.595)$ 分别对应 U_1, U_2, U_3 相对于 U 的权重。

依次可以得到次准则层指标 U_{11}, U_{12}, U_{13} 相对于准则层 U_1 的判断矩阵，如表 6 所示；次准则层指标 $U_{21}, U_{22}, U_{23}, U_{24}$ 相对于准则层 U_2 的判断矩阵，如表 7 所示；次准则层指标 U_{31}, U_{32} 相对于准则层 U_3 的判断矩阵，如表 8 所示。

表 6 U_1-U_{1i} 判断矩阵

U_1-U_{1i}	U_{11}	U_{12}	U_{13}
U_{11}	1	2	1/2
U_{12}	1/2	1	1/4
U_{13}	2	4	1

对于 U_1-U_{1i} 判断矩阵， $A_1=(0.286, 0.143, 0.571)$ ， $\lambda_{\max}=3.001$ ， $CI=0.001$ ， $CR=0.002<0.1$ ，因此该判断矩阵的一致性是可以接受的。

表 7 U_2-U_{2i} 判断矩阵

U_2-U_{2i}	U_{21}	U_{22}	U_{23}	U_{24}
U_{21}	1	1/5	1/6	1/3
U_{22}	5	1	1	3
U_{23}	6	1	1	3
U_{24}	3	1/3	1/3	1

对于 U_2-U_{2i} 判断矩阵， $A_1=(0.065, 0.384, 0.401, 0.150)$ ， $\lambda_{\max}=4.037$ ， $CI=0.012$ ， $CR=0.013<0.1$ ，因此该判断矩阵的一致性是可以接受的。

表 8 U_3-U_{3i} 判断矩阵

U_3-U_{3i}	U_{31}	U_{32}
U_{31}	1	$1/7$
U_{32}	7	1

对于 U_3-U_{3i} 二阶判断矩阵，其一致性是可以接受的， $A_1=(0.125, 0.875)$ 。

综合上述结果，对于层次总排序如下表 9 所示，从而找到次准则层相对于准则层的比重以及相对于目标层的比重。

表 9 AIGC 可信因素层次权重

U	系统可信度 U_1	媒介可信度 U_2	内容可信度 U_3	总排序权重
	0.277	0.128	0.595	
训练数据可信度 U_{11}	0.286			0.079
算法模型可信度 U_{12}	0.143			0.040
输出结果可信度 U_{13}	0.571			0.158
专业服务能力 U_{21}		0.065		0.008
社会影响力 U_{22}		0.384		0.049
立场中立性 U_{23}		0.401		0.051
保障机制构建 U_{24}		0.150		0.019
形式可信度 U_{31}			0.125	0.074
实质可信度 U_{32}			0.875	0.521

根据权重分析结果，对于 AIGC 可信度评估而言，影响程度由强至弱依此为内容因素 U_3 （权重 0.595）>系统因素 U_1 （权重 0.277）>媒介因素 U_2 （权重 0.128）。在次准则层因素层面，影响程度较强的因素有：实质可信度 U_{32} （权重 0.521）、输出结果可信度 U_{13} （权重 0.158）、训练数据可信度 U_{11} （权重 0.079）和形式可信度 U_{31} （权重 0.074）。诚然，限于媒介素养、专业知识、操作技能等多方面的差异，专家视角的重要性赋权和用户感知可信因素存在一定偏差，多层次挖掘 AIGC 可信因素对于防范传播风险和保障内容生态安全具备重要作用。

四 结果与讨论：多层可信线索与逐层递进归谬

（一）技术痛点：从知识盲区到非线性涌现

技术系统的成熟度和可塑性是影响 AIGC 可信度的底层原因，研究发现，输出结果可信度（权重 0.571）、训练数据可信度（权重 0.286）是影响系统可信进而作用于 AIGC 可信度的重要因素。对于当前通用性 AIGC 产品而言，泛知识领域的语料训练虽然增强了模型的普适性，但也在一定程度上限制了其在特定领域或专业知识范畴内容的训练深度，且目前多数 AIGC 产品对专业知识内容的调用能力有限，因此在部分领域形成了“知识盲区”。而生成式 AI 基于大语言模型训练和模型优化，展现出“非线性涌现”能力，产生超出预设规则的创造性输出，造成 AIGC 在逻辑和合理性上的不稳定性，甚至出现模型“幻觉”。

因此为提升 AIGC 的系统可信度需从输出结果、训练数据、算法等多个层面持续优化。在训练数据层面，保障数据的质量、多样性和代表性是基础。高质量的训练数据能够提升生成内容的准确性和可靠性，并减少模型偏见和错误输出的可能性。因此在 AIGC 产品设计中需保障训练数据的质量，注重数据来源的透明性，确保数据的多样性和覆盖范围，避免因数据偏差导致的生成内容失真。而为优化 AIGC 产品输出结果的质量，可通过实时验证机制 和多轮迭代减少错误，同时向用户展示生成内容的来源、推理过程以及相关的上下文信息，帮助用户理解内容的生成逻辑，降低模型“幻觉”生成的概率，以此增强用户信任。此外，尽管算法模型可信的权重相对较低，但提升算法的透明度和可解释性对用户信任的构建同样重要，能够帮助用户理解生成内容的可信度边界。

（二）媒介差异：从政治内嵌到资本操纵

AIGC 平台作为一种媒介载体，其媒介可信度（权重 0.128）显著影响用户对 AIGC 可信度感知，且平台的立场中立性（权重 0.401）和社会影响力（权重 0.384）对媒介可信产生重要影响。AIGC 平台其运营平台主体的政治偏向和利益取向会促使数据择取和模型调参上形成选择性偏见，进而影响生成内容的中立性和全面性。这种政治内嵌不仅影响信息的客观性，无形中通过算法强化了特定的政治立场，削弱公共领域的理性对话基础。此外，生成式 AI 的训练数据往往来源于互联网上的大规模数据集，开源数据集往往映射各类社会组织和

个体的价值观点和意识形态倾向。资本市场对数据源头和算法设计的“干扰”，间接影响生成内容的价值取向。

综合来看，作为传播平台，媒介差异深植于政治与资本的复杂关联中。AIGC 技术的中立性并不能天然保证其作为传播平台的可信度。只有通过强化平台的立场中立性和社会影响力，才能有效提升其可信度，并为信息生态治理提供切实可行的路径。强化平台的中立性需从技术透明度和监管机制等方面入手，确保能够对平台内容生成进行定期审查。此外，需关注平台的社会角色，平台的社会影响力不仅是其传播能力的体现，更是其塑造公众认知、引导舆论和构建社会信任的重要工具。因此需强调平台的社会责任，可通过建立社会责任报告制度，平台定期向社会公开其治理成效，以增强公众信任。

（三）内容线索：从认知捷径到形式信任

相较于技术和媒介因素，内容因素是影响用户感知可信的第一要素，研究发现内容可信度（权重系数 0.595）对 AIGC 可信度的影响高于系统可信度（权重系数 0.277）和媒介可信度（权重系数 0.128）。在可信内容线索中，从专家视角来看，实质可信度（权重系数 0.875）相比于形式可信度（权重系数 0.125）更重要，对于普通用户而言，对内容形式等显性线索的依赖度往往强于需要推理判断的隐性线索，显性的具备规范引用来源和权威背书的生成内容，其可信度更高。

在实时的人机交互过程中，用户在短时间内可获取批量生成式内容，由于逻辑推理形成的理性判断需要更多的时间和思考，基于直觉和经验的感性判断力往往占据主导。内容层面的可信线索触发用户已有认知框架，增强其信任感知，从而形成一种认知捷径。整体而言，表层的启发式线索作为一种快速而经验主义的思考方式，是用户可信度判断的重要依据，其所形成的初步信任会进一步影响后续人机交互频度和深度。这种基于表面特征的信任模式往往是在信息不完整或时间有限的情境下，用户基于简化规则或启发式策略形成模糊感知，虽然能减少认知负荷和决策时间，但往往也会导致不准确判断和偏见强化。

从具体可信线索来看，目前常见的 AIGC 产品在信源专业度、权威背书方面有待提升，当前 AIGC 产品对形式上的可信线索关注度尚有不足。在 AIGC 产品设计中可通过展示信源的专业性、引用规范性、响应一致性等方面，从系统层面完善多层可信线索的提示，从而提升用户对 AIGC 的信任度。结合表层线索导向的形式信任，通过深入推理和信息溯源形成的实质信任更能强化用户粘性，在更深层次提升人机信任程度。

（四）反制策略：从反向指令到递进归谬

综合来看，目前 AIGC 产品已实现基本可供可用，但在可信维度还需从技术系统层面、媒介传播层面、内容规制层面进行多维迭代。长期来看，除了前述提到从数据质量、算法设计、平台立场、社会影响力、内容形式及实质可信等方面构建持续完善 AIGC 的可信机制。短期而言，在人机交互过程中可以通过反向指令逐层挖掘内容可信线索，亦可形成逐层递进式归谬路径，从而在一定程度上规避 AIGC 衍生的失实信息传播和误导性认知。

具体而言，反向指令包括反向信息溯源、反向事实验证、反向逻辑验证、反向模型对比等可信线索挖掘方式。其中反向信息溯源主要针对 AIGC 的信息来源和参考依据进行逐层递进式追问，并结合信源比对来判断其可信程度；反向事实验证则是基于 AI 提供结论要求其提供可被验证的事实信息或证据材料，结合事实要素核实其可信度；反向逻辑验证则需在多层递进追问中判断 AIGC 的逻辑连贯性和前后一致性，通过上下文的逻辑自洽度去检验可信度；反向模型对比则涉及到对多个生成式 AI 模型输出内容的比对核验，通过内容一致性程度和冲突矛盾程度来进行内容归谬。

五 结语

AIGC 的可信度既是一个技术问题，又是一个传播问题，同时也是一个社会问题。本研究探讨如何对 AIGC 可信度进行评估这一热点议题，搭建了 AIGC 可信度评估体系框架，基于层析分析法，在专家充分论证的基础上，明晰 AIGC 可信度的主要影响要素，并提出从系统技术、媒介平台、内容线索以及用户反向验证等方面增强 AIGC 可信的优化策略。理论层面，本研究强调技术、媒介、内容多维度的可信度评估视角，为后续研究提供了理论参考和分析工具，亦拓展了媒介可信度理论的应用范围。实践层面，为 AIGC 产品优化设计、用户信任构建、信息生态治理提供借鉴。但囿于样本范围和主观评判导致偏差等原因，未来研究需进一步开展更大规模的专家群体或用户的实证分析，对评估体系进行验证，以完善 AIGC 可信度评估体系，促进 AIGC 技术健康发展，为信息生态治理提供更加科学和全面的支持。

参考文献

- [1] YU P, XIA Z, FEI J, et al. A survey on deepfake video detection[J]. *Iet Biometrics*, 2021, 10(6): 607-624.
- [2] WHYTE C. Deepfake news: AI-enabled disinformation as a multi-level public policy challenge[J]. *Journal of cyber policy*, 2020, 5(2): 199-217.
- [3] ILLIA L, COLLEONI E, ZYGLIDOPOULOS J. Ethical implications of text generation in the age of artificial intelligence[J]. *Business ethics, the environment & responsibility*, 2023, 32(1): 201-210.
- [4] WU Y, MOU Y, LI Z, et al. Investigating American and Chinese subjects' explicit and implicit perceptions of AI-generated artistic work[J]. *Computers in human behavior*, 2020, 104: 106186.
- [5] 蒋忠波, 师雪梅, 张宏博. 人机传播视域下算法新闻可信度的感知研究——基于一项对大学生的控制实验分析[J]. *国际新闻界*, 2022, 44(3): 34-52.
- [6] 吴丹, 孙国焯. 生成式智能搜索结果可信度研究[J]. *中国图书馆学报*, 2023, 49(6): 51-67.
- [7] FOGG B J, TSENG H. The elements of computer credibility[C]//*Proceedings of the SIGCHI conference on human factors in computing systems*. 1999: 80-87.
- [8] 宋士杰, 赵宇翔, 朱庆华. 从 ELIZA 到 ChatGPT: 人智交互体验中的 AI 生成内容可信度评价[J]. *情报资料工作*, 2023, 44(04): 35-42.
- [9] 刘海明, 李佳怿. “相信一段程序”: ChatGPT 生成内容的认知途径与算法信任建构[J]. *传媒观察*, 2024(05): 71-79.
- [10] European Commission. Ethics guidelines for trustworthy AI [EB/OL]. <https://www.i-programmer.info/programming/artificial-intelligence/12702-ethics-guidelinesfor-trustworthy-ai-.html>
- [11] OECD Legal Instruments. Recommendation of the council on artificial intelligence [EB/OL]. <https://legalinstruments.oecd.org/en/instruments/OECD-LEGAL-0449>
- [12] SINGH R, VATSA M, RATHA N. Trustworthy ai[C]//*Proceedings of the 3rd ACM india joint international conference on data science & management of data*. 2021: 449-453.
- [13] FUJII G, HAMADA K, ISHIKAWA F, et al. Guidelines for quality assurance of machine learning-based artificial intelligence[J]. *International journal of software engineering and knowledge engineering*, 2020, 30(11-12): 1589-1606.
- [14] 何积丰. 安全可信人工智能[J]. *信息安全与通信保密*, 2019(10): 5-8.

- [15] SCHWEIGER W. Media credibility—experience or image? A survey on the credibility of the World Wide Web in Germany in comparison to other media[J]. *European journal of communication*, 2000, 15(1): 37-59.
- [16] METZGER M J, FLANAGIN A J, EYAL K, et al. Credibility for the 21st century: Integrating perspectives on source, message, and media credibility in the contemporary media environment[J]. *Annals of the international communication association*, 2003, 27(1): 293-335.
- [17] 李晓静. 中国社会情境中的媒介可信度研究[M]. 上海: 上海交通大学出版社, 2019: 148.
- [18] 张洪忠, 任吴炯. 超越“第二自我”的人机对话——基于 AI 大模型应用的信任关系探讨[J]. *新闻大学*, 2024(3): 47-60.
- [19] SUNDAR S S. The MAIN model: A heuristic approach to understanding technology effects on credibility[M]. Cambridge, MA: Macarthur foundation digital media and learning initiative, 2008: 73-100.
- [20] FLANAGIN A J, METZGER M J. The role of site features, user attributes, and information verification behaviors on the perceived credibility of web-based information[J]. *New media & society*, 2007, 9(2): 319-342.
- [21] HILLIGOSS B, RIEH S Y. Developing a unifying framework of credibility assessment: Construct, heuristics, and interaction in context[J]. *Information processing & management*, 2008, 44(4): 1467-1484.
- [22] 中国质量报. 中国信通院发布“可信 AI”人工智能数据集质量评估体系[EB/OL]. https://www.cqn.com.cn/zgzb/content/2024-12/31/content_9085042.htm
- [23] 刘晗, 李凯旋, 陈仪香. 人工智能系统可信性度量评估研究综述[J]. *软件学报*, 2023, 34(8): 3774-3792.
- [24] KAUR D, USLU S, RITTICHER K J, et al. Trustworthy artificial intelligence: a review[J]. *ACM computing surveys*, 2022, 55(2): 1-38.
- [25] 潘霁. 从反映真实到象征架构: 网络环境的信息可信度评估[J]. *现代传播(中国传媒大学学报)*, 2018, 40(11): 86-90.
- [26] HOVLAND C I, WEISS W. The influence of source credibility on communication effectiveness[J]. *Public opinion quarterly*, 1951, 15(4): 635-650.
- [27] WALSTER E, ARONSON V, ABRAHAMS D, et al. Importance of physical attractiveness in dating behavior[J]. *Journal of personality and social psychology*, 1966, 4(5): 508.

[28] 祝建华. 中文传播研究之理论化与本土化: 以受众及媒介效果的整合理论为例[J]. 新闻学研究, 2001, 68: 1-22.

[29] GOLAN G J. New perspectives on media credibility research[J]. American behavioral scientist, 2010, 54(1): 3-7.

[30] 李晓静, 刘祎宁. 融媒体如何促进中国青年的政治信任? —基于链式双重中介模型的考察[J].新闻界, 2023, (09): 46-57.

[31] POWELL T E, Boomgaarden H G, DE SWERT K, et al. Framing fast and slow: A dual processing account of multimodal framing effects[J]. Media Psychology, 2019, 22(4): 572-600.

[32] GUPTA A, KUMARAGURU P, CASTILLO C, et al. Tweetcred: Real-time credibility assessment of content on twitter[C]// International conference on social informatics. 2014: 228-243.

[33] SLATER M D, ROUNER D. How message evaluation and source attributes may influence credibility assessment and belief change[J]. Journalism & mass communication quarterly, 1996, 73(4): 974-991.

[34] FAIRBANKS J, FITCH N, KNAUF N, et al. Credibility assessment in the news: do we need to read[C]//Proceeding of the MIS2 workshop held in conjunction with 11th international conference on web search and data mining. 2018: 799-800.

[35] LEDERMAN R, FAN H, SMITH S, et al. Who can you trust? Credibility assessment in online health forums[J]. Health policy and technology, 2014, 3(1): 13-25.